Práctica 5: Sistema de Autenticación Biométrica Segura y Sistema de Alerta ante Detección de Datos Anómalos

Autores:

Diego Esclarín (51729611N)
Sofía Contreras (09848471D)

Aplicaciones de Inteligencia Artificial
Grado en Ingeniería en Inteligencia Artificial
Universidad Rey Juan Carlos
Curso 2025–26

Índice

1. Introducción **5**
1.1. Objetivos del Proyecto 5
1.2. Alcance y Limitaciones 5

2. Contexto **7**
2.1. Marco del Problema 7
2.2. Marco Académico y Normativo 7
2.3. Datos Disponibles 7

3. Estado del Arte **9**
3.1. Detección y Alineamiento Facial 9
3.2. Generación de *Embeddings* Faciales 9
3.3. Detección de Ataques de Presentación 9
3.4. Protección de Plantillas Biométricas 9
3.5. Detección de Anomalías 9

4. Propuesta **11**
4.1. Arquitectura General 11
4.2. Pipeline de Verificación 11
4.3. Esquema de Seguridad 11
4.4. Calibración y Evaluación 12
4.5. Resultados Experimentales 12
4.6. Módulo Financiero 16

5. Conclusiones **17**

Índice de figuras

1. Ejemplos del conjunto de test del detector de *liveness*: fila superior muestras reales (*live*) y fila inferior ataques de presentación (*spoof*). Se indica el *score* de probabilidad de ser real predicho por el modelo. 13
2. Comparación directa de un *frame* etiquetado como verdadero (izquierda) frente a uno etiquetado como falso (derecha) con su *score* de *liveness* asociado. 14
3. Curva ROC del detector de *liveness* sobre el conjunto de test. Se marca en rojo el punto de operación correspondiente al umbral configurado. 14
4. Distribución de *scores* de *liveness* para muestras reales (verde) y de ataque (rojo), con el umbral actual y el umbral correspondiente al *Equal Error Rate*. 15
5. Matriz de confusión del detector de *liveness* sobre la partición de test del dataset. 15

1. Introducción

El propósito de esta práctica es el diseño e implementación de un sistema de autenticación biométrica facial robusto, orientado a entornos de producción y construido bajo el paradigma de *Security by Design*. La biometría facial se ha consolidado como uno de los factores de autenticación más cómodos para el usuario final, pero su despliegue en entornos reales requiere mitigar dos vectores críticos: los ataques de presentación (*spoofing*) y la fuga de plantillas biométricas almacenadas [1].

La arquitectura propuesta integra tres pilares: reconocimiento facial, detección de vitalidad y seguridad criptográfica. El pipeline de visión utiliza MTCNN [2] para el alineamiento, CLAHE para la normalización y ArcFace [3] o FaceNet [4] para la extracción de rasgos. Por su parte, el módulo de *liveness* (DenseNet201 [5]) actúa como barrera de seguridad previa. Además, el almacenamiento cumple con estándares de alta seguridad mediante cifrado autenticado y derivación de claves PBKDF2 según las recomendaciones del NIST [6].

También se incorpora un segundo módulo de aprendizaje no supervisado para el control financiero personal del usuario, basado en una combinación híbrida de la regla de las 3-Sigmas e *Isolation Forest* [7], que aporta explicabilidad y capacidad de detección de transacciones anómalas tanto univariantes como multivariantes.

1.1. Objetivos del Proyecto

Los objetivos principales se estructuran en tres niveles:

Objetivo técnico: Implementar un verificador facial *end-to-end* con detección, alineamiento, normalización fotométrica, *embedding* y comparación coseno, complementado con un detector de *liveness* CNN y un sistema de almacenamiento cifrado con verificación de integridad mediante HMAC-SHA256.

Objetivo de seguridad: Aplicar principios de *Security by Design* para garantizar la confidencialidad de las plantillas (cifrado simétrico autenticado), la integridad frente a manipulaciones del fichero de base de datos, la mitigación de ataques de fuerza bruta (*Account Lockout*) y la prevención de ataques de presentación según ISO/IEC 30107-3 [8].

Objetivo Técnico: Evaluar el rendimiento de los modelos de *embedding* y desarrollar un módulo CLI que automatice la búsqueda de umbrales óptimos para la verificación y detección de vitalidad a partir de datos etiquetados.

1.2. Alcance y Limitaciones

El sistema se centra en la verificación facial 1:1 (*login*) y la inscripción 1:N de un número reducido de usuarios mediante una interfaz por línea de comandos. Las limitaciones principales son: dependencia de la calidad de las muestras de inscripción, ausencia de despliegue en hardware dedicado (cámaras 3D o infrarrojas) que mitigaría ciertos ataques de presentación, y un detector de *liveness* entrenado sobre un conjunto público acotado, lo que condiciona su generalización a nuevos vectores de ataque.

2. Contexto

La autenticación biométrica facial se ha desplegado de forma masiva en dispositivos móviles, sistemas de control de acceso físico, banca digital y plataformas de identificación remota. Frente a los factores de autenticación tradicionales (contraseñas, tokens), la biometría facial aporta una experiencia de uso fluida pero introduce riesgos específicos: a diferencia de una contraseña, una plantilla biométrica no es revocable, por lo que su compromiso es permanente.

2.1. Marco del Problema

Un sistema de verificación facial productivo debe abordar simultáneamente tres dimensiones:

- **Precisión:** la separación entre las distribuciones de pares genuinos y de impostores debe ser suficiente para garantizar tasas de error razonables (FAR/FRR) en el punto de operación elegido.
- **Robustez frente a ataques de presentación:** fotografías impresas, reproducciones en pantalla y máscaras 3D constituyen los vectores de ataque más habituales en entornos no controlados [1].
- **Protección de las plantillas:** los *embeddings* almacenados deben tratarse como datos personales sensibles, cumpliendo principios de confidencialidad e integridad.

2.2. Marco Académico y Normativo

El sistema se inspira en el estándar ISO/IEC 30107-3 [8] para evaluación de detección de ataques de presentación, y las recomendaciones del NIST SP 800-132 [6] para derivación de claves a partir de contraseñas.

2.3. Datos Disponibles

Para el entrenamiento y la evaluación del módulo de *liveness* se ha utilizado un conjunto público de imágenes anotadas como *real* y *spoof*. Para la evaluación del verificador se construye un conjunto de pares (`pairs.csv`) etiquetados como genuinos o impostores. El módulo de control financiero reutiliza el histórico de transacciones de la Práctica 2.

3. Estado del Arte

El reconocimiento facial moderno se basa en redes neuronales profundas que proyectan las imágenes a un espacio vectorial donde la distancia (típicamente coseno) entre representaciones de la misma identidad es pequeña. Esta sección revisa las familias de modelos y técnicas relevantes para el sistema propuesto.

3.1. Detección y Alineamiento Facial

MTCNN [2] es un detector en cascada que combina tres redes (P-Net, R-Net, O-Net) para localizar el rostro y predecir cinco puntos de referencia faciales (ojos, nariz, comisuras de la boca). Estos puntos se utilizan posteriormente para realizar un alineamiento afín que estandariza la pose y mejora notablemente el rendimiento de los *embedders* [9].

3.2. Generación de *Embeddings* Faciales

FaceNet [4] introduce el aprendizaje directo de un *embedding* 128-D mediante *triplet loss*, optimizando la separación angular entre identidades. **ArcFace** [3] mejora esta idea sustituyendo el *loss* clásico por un margen angular aditivo sobre el *softmax*, lo que produce una separación más uniforme y robusta y resulta hoy el estándar *de facto* en verificación facial.

3.3. Detección de Ataques de Presentación

Los métodos de *liveness* pasivo —que no requieren cooperación adicional del usuario— se basan en explotar artefactos espacio-temporales presentes en imágenes falsificadas: patrones de *moiré* en pantallas, distorsiones de color en impresiones, ausencia de variabilidad textural [1]. Arquitecturas convolucionales densas como DenseNet [5] resultan adecuadas porque maximizan la reutilización de *features* en distintas escalas, lo cual favorece la detección de estos artefactos.

3.4. Protección de Plantillas Biométricas

Las plantillas biométricas se consideran datos personales especialmente sensibles. Las prácticas recomendadas combinan: (i) cifrado simétrico autenticado para la confidencialidad, (ii) MAC o firma para la integridad, y (iii) derivación de claves a partir de secretos memorizables siguiendo NIST SP 800-132 [6] con un número alto de iteraciones para encarecer ataques *offline*. La especificación Fernet [10] encapsula AES-128-CBC + HMAC-SHA256 + *timestamp* en un único *token*, simplificando un esquema correcto.

3.5. Detección de Anomalías

Para el módulo financiero, *Isolation Forest* [7] es un algoritmo no supervisado que aísla observaciones anómalas mediante particiones aleatorias del espacio de *features*; las anomalías requieren menos divisiones para quedar aisladas y, por tanto, obtienen una puntuación característica. Combinado con la regla estadística de las 3-Sigmas, ofrece un compromiso entre interpretabilidad univariante y detección multivariante.

4. Propuesta

La propuesta consiste en un sistema modular de autenticación biométrica facial con almacenamiento cifrado, detección de *liveness* y un módulo accesorio de detección de anomalías financieras. Toda la funcionalidad se expone mediante una CLI orquestada en `main.py`, organizada en tres familias de comandos: gestión de usuarios, evaluación/calibración y control financiero.

4.1. Arquitectura General

El código se organiza en una estructura modular bajo `src/`: `data/` (carga y validación de datos faciales y financieros), `features/` (preprocesamiento CLAHE y MTCNN), `models/` (*embedders*, *liveness* y detección de anomalías), `evaluation/` (métricas, ROC, calibración) y `utils/` (criptografía y soporte). La configuración del sistema reside en `config/config.yaml`, lo que permite ajustar umbrales y rutas sin tocar el código.

4.2. Pipeline de Verificación

El flujo de *login* se compone de las siguientes etapas:

1. **Detección y alineamiento (MTCNN):** se localiza el rostro y se alinea afinmente a partir de cinco puntos de referencia.
2. **Liveness gate (DenseNet201):** se evalúa la imagen en crudo; si la puntuación es inferior al umbral calibrado, se rechaza la solicitud sin invocar al *embedder*.
3. **Normalización fotométrica (CLAHE):** sólo si supera el *liveness*, la imagen alineada se ecualiza para reducir variabilidad por iluminación.
4. **Embedding (ArcFace o FaceNet):** se genera un vector L2-normalizado.
5. **Comparación coseno:** se compara con la plantilla descifrada del usuario reclamado y se decide aceptar/rechazar según el umbral de similitud.
6. **Control de intentos:** en caso de rechazo se incrementa un contador por usuario que activa un bloqueo temporal tras N fallos consecutivos.

4.3. Esquema de Seguridad

La protección de las plantillas se implementa en `src/utils/` y combina tres mecanismos:

- **Confidencialidad:** cada *embedding* se serializa y se cifra con Fernet (AES-128-CBC + PKCS7) [10].
- **Derivación de clave:** la clave Fernet se obtiene en cada arranque mediante PBKDF2-HMAC-SHA256 con 310.000 iteraciones y *salt* aleatorio persistido, conforme a NIST SP 800-132 [6].
- **Integridad:** junto al ciphertext se almacena un HMAC-SHA256 del *embedding* en plano; cualquier manipulación del fichero de base de datos invalida la verificación y aborta el *login*.

4.4. Calibración y Evaluación

El subcomando `evaluate` calcula EER, ROC-AUC, F1 y TAR@FAR sobre un fichero `pairs.csv` con pares etiquetados; el subcomando `benchmark` compara latencia, rendimiento y separación coseno entre *backends*; y el subcomando `tune` barre el espacio de umbrales de similitud y de *liveness* y actualiza `config.yaml` con el punto de operación óptimo. Las salidas gráficas (curvas ROC, distribución de *scores*, comparativas DET y mapa de barrido de umbrales) se persisten en `doc/evaluation/` para su inclusión en la memoria.

4.5. Resultados Experimentales

La evaluación del detector de *liveness* se ha realizado sobre la partición de test del dataset Kaggle *real-vs-fake-anti-spoofing-video-classification*, extrayendo tres *frames* por vídeo en los segundos 3, 5 y 7 (conjunto disjunto del usado en entrenamiento). La Figura 1 muestra un mosaico representativo de muestras correctamente clasificadas en ambas clases, donde se aprecia visualmente la diferencia textural y fotométrica que el modelo aprende a discriminar.

Cuantitativamente, la Figura 3 presenta la curva ROC del detector y la Figura 4 la distribución de *scores* para ambas clases, lo que permite observar la separabilidad alcanzada y justificar la elección del umbral de operación. La matriz de confusión resultante (Figura 5) resume los aciertos y errores de clasificación, ofreciendo una lectura directa de los falsos aceptos y falsos rechazos del sistema.

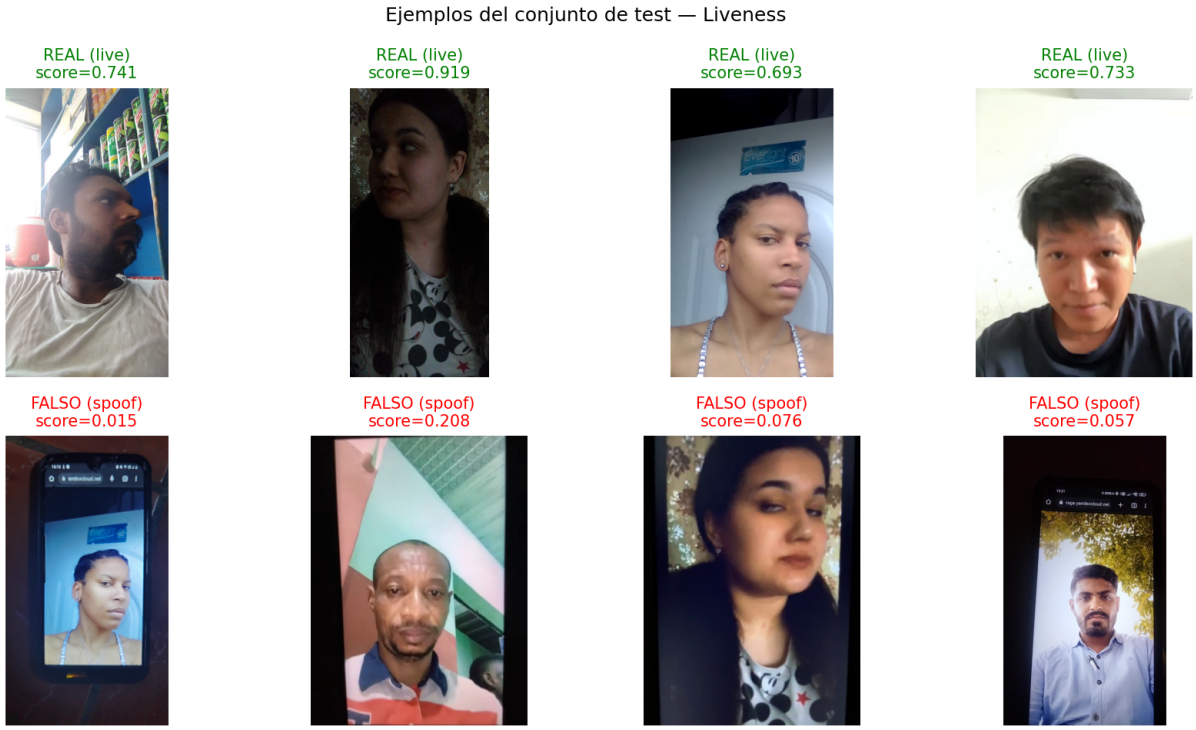

Figura 1: Ejemplos del conjunto de test del detector de *liveness*: fila superior muestras reales (*live*) y fila inferior ataques de presentación (*spoof*). Se indica el *score* de probabilidad de ser real predicho por el modelo.

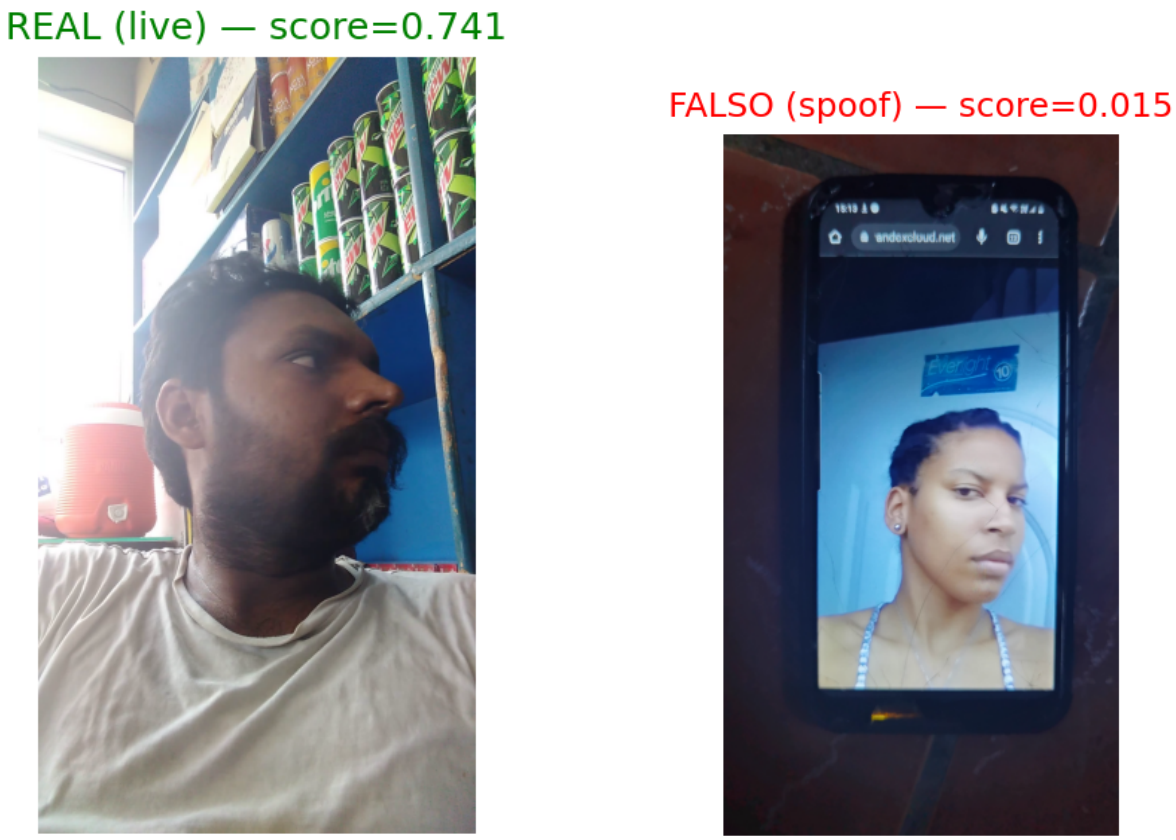

(a) Muestra real (*live*).

(b) Muestra falsa (*spoof*).

Figura 2: Comparación directa de un *frame* etiquetado como verdadero (izquierda) frente a uno etiquetado como falso (derecha) con su *score* de *liveness* asociado.

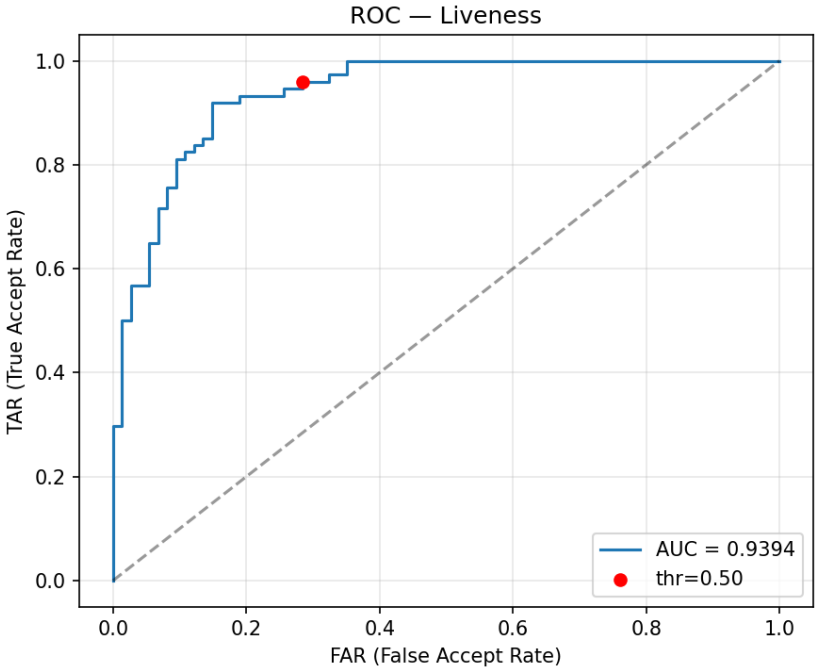

Figura 3: Curva ROC del detector de *liveness* sobre el conjunto de test. Se marca en rojo el punto de operación correspondiente al umbral configurado.

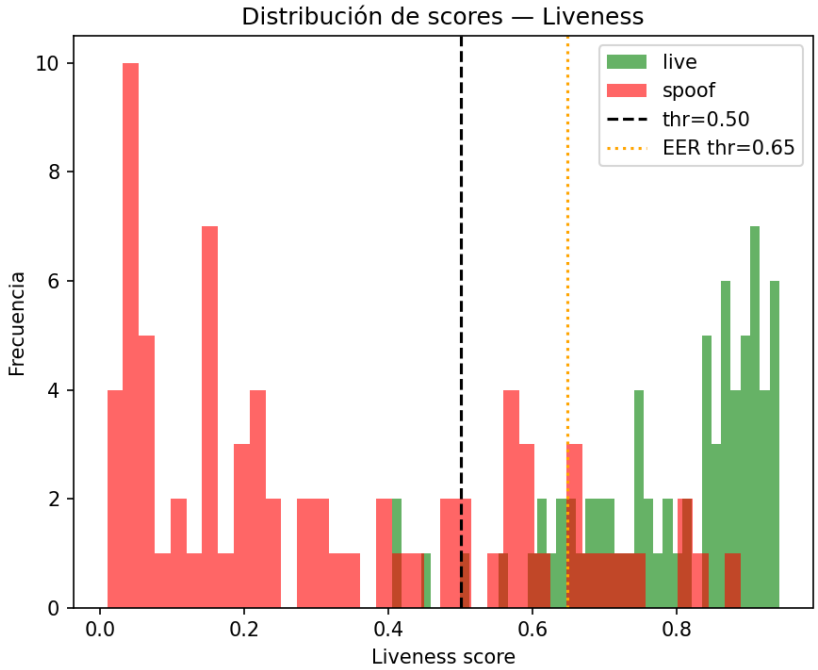

Figura 4: Distribución de *scores* de *liveness* para muestras reales (verde) y de ataque (rojo), con el umbral actual y el umbral correspondiente al *Equal Error Rate*.

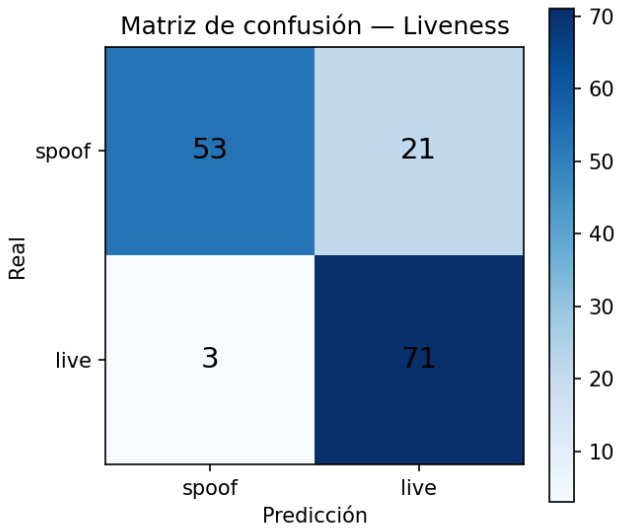

Figura 5: Matriz de confusión del detector de *liveness* sobre la partición de test del dataset.

4.6. Módulo Financiero

El comando `finance-add` valida cada nueva transacción mediante un detector híbrido: la regla de las 3-Sigmas filtra anomalías univariantes por categoría, y un *Isolation Forest* [7] captura combinaciones inusuales de `Cantidad`, `Área`, `Tipo`, `Mes` y `Día de la semana`. El modelo se reentrena tras cada confirmación, lo que aporta una adaptación continua al perfil del usuario sin requerir etiquetas.

5. Conclusiones

El sistema desarrollado demuestra que es posible construir un verificador facial robusto integrando componentes de *deep learning* consolidados (MTCNN, ArcFace/FaceNet, DenseNet201) con buenas prácticas criptográficas estándar (Fernet, PBKDF2, HMAC-SHA256). La arquitectura modular y la separación entre detección, *liveness* y *embedding* permite sustituir cualquier componente sin alterar el resto de la pipeline, lo que facilita su evolución.

El esquema de seguridad propuesto cubre las tres propiedades clave de una plantilla biométrica almacenada: confidencialidad, integridad y autenticación, eliminando la posibilidad de fugas en texto plano y detectando manipulaciones del fichero. La incorporación del *Account Lockout* mitiga ataques de fuerza bruta sobre el verificador, y el *liveness gate* reduce la superficie de ataques de presentación más comunes.

Las herramientas de calibración (`evaluate`, `benchmark`, `tune`) resultan claves para llevar el sistema a un punto de operación adecuado al contexto de despliegue, permitiendo elegir explícitamente el compromiso entre FAR y FRR. Como líneas futuras se identifican: (i) entrenar el detector de *liveness* con conjuntos más diversos para mejorar su generalización a nuevos vectores de ataque, (ii) explorar verificación basada en vídeo en lugar de imagen estática, y (iii) integrar mecanismos de *cancellable biometrics* que permitan revocar plantillas comprometidas sin necesidad de reinscripción.

Referencias Bibliográficas

[1] R. Ramachandra y C. Busch, «Presentation Attack Detection Methods for Face Recognition Systems: A Comprehensive Survey,» *ACM Computing Surveys*, vol. 50, n.º 1, 2017.

[2] K. Zhang, Z. Zhang, Z. Li e Y. Qiao, «Joint Face Detection and Alignment Using Multi-task Cascaded Convolutional Networks,» *IEEE Signal Processing Letters*, vol. 23, n.º 10, págs. 1499-1503, 2016.

[3] J. Deng, J. Guo, N. Xue y S. Zafeiriou, «ArcFace: Additive Angular Margin Loss for Deep Face Recognition,» *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.

[4] F. Schroff, D. Kalenichenko y J. Philbin, «FaceNet: A Unified Embedding for Face Recognition and Clustering,» *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2015.

[5] G. Huang, Z. Liu, L. van der Maaten y K. Q. Weinberger, «Densely Connected Convolutional Networks,» *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.

[6] M. S. Turan, E. Barker, W. Burr y L. Chen, *NIST Special Publication 800-132: Recommendation for Password-Based Key Derivation*, 2010.

[7] F. T. Liu, K. M. Ting y Z.-H. Zhou, «Isolation Forest,» *Eighth IEEE International Conference on Data Mining*, 2008.

[8] International Organization for Standardization, *ISO/IEC 30107-3:2017 Information technology — Biometric presentation attack detection — Part 3: Testing and reporting*, 2017.

[9] D. Zeng, R. Veldhuis y L. Spreeuwers, «A survey of face recognition techniques under occlusion,» *IET Biometrics*, vol. 10, n.º 6, págs. 581-606, 2021.

[10] Cryptography.io, *Fernet Specification*, `https://cryptography.io/en/latest/fernet/`, 2024.